

Previsão de Preço de Carros Usados com Técnicas de Aprendizado de Máquina e Mineração de Dados

Luis Ricardo Santos
Programa de Pós-Graduação
Universidade Federal de Itajubá (UNIFEI)
Itajubá, Brasil
luis.ricardo@unifei.edu.br

Integrante 2
Programa de Pós-Graduação
Universidade Federal de Itajubá (UNIFEI)
Itajubá, Brasil
email@unifei.edu.br

Integrante 3
Programa de Pós-Graduação
Universidade Federal de Itajubá (UNIFEI)
Itajubá, Brasil
email@unifei.edu.br

Abstract—A precificação de veículos usados é um problema de regressão de elevada relevância econômica, marcado por relações não lineares entre idade, quilometragem e especificações mecânicas. Neste trabalho, técnicas de aprendizado de máquina e mineração de dados foram aplicadas para prever o preço de venda de carros usados a partir de um conjunto de dados real do mercado indiano, composto por 8.128 anúncios. Após limpeza, engenharia de atributos e análise exploratória apoiada por Análise de Componentes Principais, o preço foi modelado em escala logarítmica e seis algoritmos foram comparados por validação cruzada de cinco dobras com partição agrupada pelo veículo, de modo a impedir vazamento de informação. Os métodos de comitê obtiveram o melhor desempenho; o XGBoost foi o mais acurado, com coeficiente de determinação de 0,916 no conjunto de teste e erro percentual absoluto médio de 16,2 por cento, superando de forma estatisticamente significativa o gradient boosting. A interpretação por permutação indicou que o ano do veículo, a potência e o torque são os preditores mais relevantes. Demonstra-se, assim, um fluxo metodológico completo, robusto e transferível para problemas tabulares de precificação.

Index Terms—aprendizado de máquina, regressão, XGBoost, floresta aleatória, validação cruzada, mineração de dados, precificação

I. INTRODUÇÃO

A. Contexto

A avaliação do preço de veículos usados é uma atividade economicamente significativa, presente em concessionárias, plataformas de anúncios e instituições financeiras. O preço de um automóvel usado resulta da interação de múltiplos fatores — idade, quilometragem rodada, especificações técnicas, marca e condições de mercado — que se relacionam de forma predominantemente não linear. Erros sistemáticos de precificação acarretam prejuízo financeiro direto, seja pela subavaliação de um ativo, seja pela perda de competitividade quando o preço é superestimado. Nesse cenário, modelos preditivos automáticos oferecem apoio à decisão consistente e escalável.

B. Objetivos

O objetivo principal deste trabalho, desenvolvido no âmbito da disciplina de Aprendizado de Máquina e Mineração de Dados [13], é desenvolver e comparar modelos preditivos capazes de estimar o preço de venda de carros usados a partir de suas características. Como objetivos secundários, destacam-se: (i) comparar sistematicamente seis algoritmos de naturezas distintas; (ii) avaliar o efeito da transformação logarítmica da variável-alvo; (iii) otimizar os hiperparâmetros e mitigar o vazamento de informação por meio de partição agrupada; e (iv) interpretar de forma robusta quais atributos mais influenciam a previsão.

C. Perguntas de Pesquisa

A investigação é orientada por três perguntas de pesquisa: **(PP1)** em que medida atributos de idade e de especificação mecânica explicam o preço de carros usados? **(PP2)** modelos de comitê superam um *baseline* linear e métodos baseados em vizinhança neste domínio tabular, e em que magnitude? **(PP3)** qual é o compromisso entre acurácia, estabilidade de generalização e custo computacional entre os modelos avaliados?

II. REVISÃO BIBLIOGRÁFICA

A. Fundamentação Teórica

A previsão de preço configura uma tarefa de regressão supervisionada, na qual se busca uma função que mapeie atributos de entrada em um valor contínuo. A regressão linear constitui o *baseline* clássico, assumindo relação aditiva entre preditores e resposta [2]. Métodos baseados em vizinhança, como o *k*-vizinhos mais próximos, estimam o valor de uma amostra pela média ponderada das *k* instâncias mais similares,

$$\hat{y}(\mathbf{x}) = \frac{\sum_{j \in N_k(\mathbf{x})} w_j y_j}{\sum_{j \in N_k(\mathbf{x})} w_j}, \quad w_j = \frac{1}{d(\mathbf{x}, \mathbf{x}_j)}, \quad (1)$$

em que $N_k(\mathbf{x})$ é o conjunto dos k vizinhos e $d(\cdot)$ a distância; o método não impõe forma funcional, mas degrada-se em espaços de alta dimensão.

Os métodos de comitê (*ensemble*) combinam múltiplos estimadores para reduzir o erro. A floresta aleatória [3] emprega *bagging* e amostragem aleatória de atributos para construir B árvores descorrelacionadas T_b , cuja média reduz a variância do preditor,

$$\hat{y}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}). \quad (2)$$

O *gradient boosting* [4] ajusta árvores rasas h_m de forma sequencial, cada uma corrigindo os resíduos da anterior, atacando principalmente o viés,

$$F_M(\mathbf{x}) = \sum_{m=1}^M \nu \gamma_m h_m(\mathbf{x}), \quad (3)$$

em que ν é a taxa de aprendizado e γ_m o peso de cada árvore. O XGBoost [5] é uma implementação otimizada do *boosting* que acrescenta regularização explícita e amostragem de atributos, frequentemente apontada como estado da arte em dados tabulares. A Análise de Componentes Principais é amplamente utilizada na etapa exploratória para revelar a estrutura de covariância e a redundância entre atributos [2].

B. Trabalhos Relacionados

A previsão de preço de veículos usados tem sido investigada com diversas abordagens. Em [6], comparam-se regressão linear, floresta aleatória e XGBoost, com vantagem dos métodos baseados em *boosting*. De forma semelhante, [7] avalia regressão linear, LASSO, árvore de decisão, floresta aleatória e *boosting* extremo, reportando os comitês como mais acurados. Estudos dedicados ao XGBoost [8] e à floresta aleatória [9] confirmam o bom desempenho dos métodos de árvore neste domínio, enquanto [10] integra tais modelos em uma aplicação de precificação. Trabalhos de mineração de dados corroboram a relevância de atributos como quilometragem, marca e cilindrada [11].

C. Lacuna Identificada

A literatura concentra-se majoritariamente na comparação de acurácia entre algoritmos, dedicando menor atenção à análise conjunta da estabilidade de generalização, da significância estatística das diferenças entre modelos e das ressalvas metodológicas da interpretação por importância de variáveis. Sobretudo, raramente se controla o vazamento de informação decorrente de veículos idênticos presentes simultaneamente em treino e teste. Este trabalho busca preencher tais lacunas ao integrar, em um mesmo fluxo reprodutível, a partição agrupada, o ajuste de hiperparâmetros, a comparação por validação cruzada com teste estatístico e a interpretação por permutação.




Fig. 1. Diagrama geral da proposta: fluxo metodológico da previsão de preço, da aquisição dos dados à interpretação dos resultados.

III. METODOLOGIA

A. Dados

Utilizou-se o conjunto de dados *Car details v3*, de domínio público, contendo 8.128 anúncios de carros usados no mercado indiano [1]. As variáveis originais incluem o nome do veículo, o ano, o preço de venda, a quilometragem, o tipo de combustível, o tipo de vendedor, a transmissão, o número de proprietários anteriores, o consumo, a cilindrada, a potência e o torque.

O pré-processamento, sintetizado no fluxograma da Fig. 1, seguiu etapas encadeadas. Inicialmente, 1.202 registros duplicados foram removidos, restando 6.926. Em seguida, realizou-se engenharia de atributos: a marca e o modelo foram extraídos do nome do veículo, e os campos textuais de consumo, cilindrada, potência e torque foram convertidos em valores numéricos. O tratamento de *outliers* eliminou registros fora dos percentis 1 e 99 de preço e de quilometragem, bem como veículos anteriores a 1990, resultando em **6.663 amostras**. Os valores ausentes foram imputados pela mediana, no caso das variáveis numéricas, e pela moda, no caso das categóricas. Por fim, as variáveis categóricas foram codificadas pela técnica *One-Hot* e as numéricas foram padronizadas pelo *score-z*. Todas as transformações foram ajustadas exclusivamente sobre o conjunto de treino, evitando vazamento de informação durante a validação cruzada.




Fig. 2. Análise exploratória: distribuição do preço e do seu logaritmo, relação entre ano e preço, e matriz de correlação entre atributos numéricos.




Fig. 3. Variância explicada por componente principal e curva acumulada (scree plot).

B. Análise Exploratória

A análise exploratória, sintetizada na Fig. 2, revelou que a distribuição do preço é fortemente assimétrica à direita, com mediana de INR 400 mil inferior à média de INR 484 mil — o que motiva a transformação logarítmica adotada na modelagem, cujo histograma resultante é aproximadamente simétrico. O preço cresce com o ano do veículo e a matriz de correlação evidencia associação positiva forte entre preço, potência e torque, e associação negativa com a quilometragem. Observa-se ainda elevada correlação mútua entre os atributos de motor, o que antecipa redundância de informação.

A redundância entre atributos foi confirmada por Análise de Componentes Principais sobre as variáveis numéricas padronizadas, excluindo o preço. Conforme o gráfico de variância da Fig. 3, três componentes concentram cerca de 80% da variância total; a primeira componente é dominada pelos atributos de motor, enquanto a quilometragem e o consumo ganham peso na segunda.

TABLE I
CONFIGURAÇÃO PRINCIPAL DOS MODELOS

Modelo	Configuração
Regressão linear	sem hiperparâmetros
Árvore de decisão	profundidade 12; mín. 5 amostras/folha
k -vizinhos	$k = 7$; ponderação por distância
Gradient boosting	150 árvores; prof. 3; taxa 0,08
Floresta aleatória	120 árvores; prof. 16; mín. 2/folha (busca em grade)
XGBoost	300 árvores; prof. 4; taxa 0,08; subamostragem 0,9

Algoritmo 1. Treino e avaliação comparativa

- 1) Particionar os dados em treino (80%) e teste (20%), agrupando pelo veículo.
- 2) Para cada modelo do conjunto de candidatos:
 - a) Encadear pré-processamento e modelo com alvo em escala log, Eq. (4).
 - b) Estimar o desempenho por validação cruzada agrupada de cinco dobras.
 - c) Registrar média e desvio-padrão das métricas entre as dobras.
 - d) Reajustar no treino completo e avaliar no conjunto de teste.
- 3) Selecionar o melhor modelo pela menor raiz do erro quadrático médio em validação cruzada.
- 4) Comparar os dois melhores por teste estatístico, interpretar e analisar resíduos.

C. Modelos

Dada a forte assimetria à direita observada na distribuição do preço, optou-se por modelar a variável-alvo em escala logarítmica. Em vez de aprender o preço y diretamente, cada modelo aprende uma função $g(\mathbf{x})$ sobre $z = \log(1 + y)$, com predição final obtida pela transformação inversa

$$\hat{y} = \exp(g(\mathbf{x})) - 1. \quad (4)$$

Como o preço é estritamente positivo e assimétrico, a transformação (4) aproxima a distribuição do alvo de uma normal, estabiliza a variância e converte relações multiplicativas em aditivas.

Para impedir o vazamento de informação, a partição treino-teste e a validação cruzada foram **agrupadas pelo nome do veículo**: amostras de um mesmo modelo, com especificações idênticas, jamais figuram simultaneamente em treino e teste. Resultaram 5.183 amostras de treino e 1.480 de teste, sem nenhuma sobreposição de grupos. Foram avaliados seis algoritmos, cujas configurações principais constam da Tabela I: regressão linear, árvore de decisão, k -vizinhos mais próximos, gradient boosting, floresta aleatória — com hiperparâmetros ajustados por busca em grade com validação cruzada agrupada — e XGBoost. O procedimento de treino e avaliação é descrito no Algoritmo III-C.

D. Avaliação

A avaliação empregou validação cruzada de cinco dobras sobre o conjunto de treino. Sejam y_i o preço real, $\hat{y}_i$ o preço




Fig. 4. Comparação do coeficiente de determinação e do erro percentual absoluto médio dos seis modelos no conjunto de teste.

previsto, $\bar{y}$ a média dos preços e n o número de amostras. Foram adotadas quatro métricas complementares:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (5)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (6)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|}, \quad (7)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}. \quad (8)$$

A significância da diferença entre os dois melhores modelos foi avaliada por um teste t pareado sobre o R^2 das cinco dobras. Métricas de classificação, como acurácia e curva ROC, não se aplicam, por se tratar de um problema de regressão.

IV. EXPERIMENTOS E RESULTADOS

A Tabela II apresenta o desempenho dos seis modelos, conforme o fluxo da Fig. 1. Os métodos de comitê apresentaram os menores erros. O **XGBoost** foi o mais acurado em todas as métricas, com $R^2 = 0,916$ no conjunto de teste, erro absoluto médio de INR 65,0 mil e erro percentual de 16,2%, seguido pelo gradient boosting ($R^2 = 0,896$). A Fig. 4 sintetiza visualmente esse ordenamento.

A regressão linear, mesmo após a transformação logarítmica, e a árvore de decisão isolada figuraram entre os modelos mais limitados; esta última foi a mais sensível à partição agrupada ($R^2 = 0,799$), coerente com sua natureza de alta variância. Esse ordenamento responde à **PP2**: os comitês superam o *baseline* linear em cerca de quatro pontos percentuais de R^2 e reduzem o erro percentual de 17,5% para 16,2%.

A. Significância Estatística

Para verificar se a vantagem do XGBoost sobre o gradient boosting é consistente, aplicou-se um teste t pareado sobre o R^2 das cinco dobras da validação cruzada. Obteve-se $t = 2,90$ e $p = 0,044$, valor inferior a 0,05; conclui-se que a superioridade do XGBoost é **estatisticamente significativa**. Esse resultado endereça a **PP3**: o ganho de acurácia do XGBoost não é fruto do acaso amostral. Ressalta-se ainda que os comitês apresentaram os menores desvios-padrão de R^2 entre as dobras (XGBoost $0,881 \pm 0,029$; gradient boosting $0,869 \pm 0,025$),




Fig. 5. Importância por permutação das variáveis segundo o melhor modelo (XGBoost): queda média no R^2 ao permutar cada atributo.

contra $0,795 \pm 0,033$ da árvore isolada, evidenciando previsões mais consistentes.

B. Benchmarking com a Literatura

A Tabela III posiciona os resultados obtidos frente a estudos correlatos. Como os conjuntos de dados diferem, a comparação é qualitativa; ainda assim, o R^2 de 0,916 alcançado situa-se acima da faixa tipicamente reportada (0,77 a 0,93), o que sugere boa competitividade da abordagem, sobretudo por adotar partição agrupada, condição mais rigorosa e menos frequente na literatura.

C. Interpretação por Permutação

A importância das variáveis foi avaliada por permutação — que mede a queda de R^2 ao embaralhar cada atributo no conjunto de teste — método mais robusto que a importância por impureza. Conforme a Fig. 5, respondendo à **PP1**, o ano do veículo é o preditor dominante (queda de 0,49 no R^2), seguido da potência (0,29), do torque (0,09) e, notavelmente, da marca (0,07), cuja relevância é maior do que a sugerida pela importância por impureza. A cilindrada, a quilometragem e a transmissão completam o conjunto de atributos influentes. Esse resultado é coerente com a Análise de Componentes Principais, na qual os atributos de motor dominam a primeira componente.

A análise de resíduos do melhor modelo é apresentada na Fig. 6. A nuvem de resíduos está aproximadamente centrada em zero e sua distribuição é simétrica, o que indica ausência de viés sistemático relevante; o treino em escala logarítmica mitigou boa parte da heterocedasticidade típica de variáveis de preço.

V. DISCUSSÃO

A comparação entre as famílias de modelos ilustra didaticamente o dilema viés-variância. A regressão linear exibe alto viés (subajuste): é estável, porém limitada, pois o efeito da potência sobre o preço varia conforme a marca e a categoria

TABLE II
DESEMPENHO DOS MODELOS NA VALIDAÇÃO CRUZADA AGRUPADA (CV, 5 DOBRAS) E NO CONJUNTO DE TESTE

Modelo	CV MAE	CV RMSE	CV R ²	CV MAPE	Teste RMSE	Teste MAPE	Teste R ²
Regressão linear	79.079	133.910	0,847	17,6%	125.663	17,5%	0,877
Árvore de decisão	91.814	155.336	0,795	21,3%	160.497	21,4%	0,799
<i>k</i> -vizinhos mais próximos	86.136	145.094	0,818	19,7%	138.288	19,8%	0,851
Gradient boosting	75.698	123.926	0,869	17,2%	115.459	17,0%	0,896
Floresta aleatória (ajustada)	78.360	132.325	0,850	18,0%	122.037	17,8%	0,884
XGBoost	71.839	117.532	0,881	16,5%	103.740	16,2%	0,916

MAE e RMSE em rúpias indianas (INR). Em negrito, o melhor valor de cada métrica.

TABLE III
COMPARAÇÃO COM TRABALHOS RELACIONADOS (R² NO TESTE)

Trabalho	Melhor modelo	R ²
Itm <i>et al.</i> [6]	XGBoost	≈ 0,87
Revolutionizing [8]	XGBoost	≈ 0,87–0,93
How much [9]	Floresta aleatória	≈ 0,83
Este trabalho	XGBoost	0,916

Conjuntos de dados distintos; comparação qualitativa.




Fig. 6. Análise de resíduos do melhor modelo: dispersão dos resíduos em função das previsões (esquerda) e distribuição dos resíduos (direita).

do veículo — interação que um modelo aditivo não representa. O método de vizinhança sofre com a maldição da dimensionalidade, agravada pela codificação *One-Hot*. A árvore de decisão isolada, de alta variância, foi a mais penalizada pela partição agrupada. Os comitês corrigem essa fragilidade: a floresta aleatória reduz a variância pela média de árvores descorrelacionadas, enquanto o gradient boosting e o XGBoost reduzem o viés de forma sequencial; o XGBoost beneficia-se ainda de regularização explícita, o que explica seu desempenho superior e estatisticamente significativo.

A interpretação por permutação corrige uma limitação importante da importância por impureza, que tende a superestimar variáveis contínuas e de alta cardinalidade e a subdimensionar variáveis categóricas fragmentadas pela codificação *One-Hot*. Ao permutar atributos no conjunto de teste, obteve-se uma estimativa mais fiel, na qual a marca emergiu como fator relevante. Ainda assim, atributos de motor fortemente correlacionados podem repartir a importância entre si, de modo que os valores devem ser lidos como tendências.

A. Limitações

Destacam-se quatro limitações: (i) os dados restringem-se a um único mercado, o que limita a generalização externa;

(ii) o nome do veículo foi reduzido à marca e ao modelo, descartando informação de versão; (iii) o conjunto apresenta desbalanceamento entre marcas; e (iv) não foi realizada validação temporal, embora preços variem ao longo do tempo.

B. Contribuições

Do ponto de vista acadêmico, a contribuição reside na integração, em um fluxo reproduzível, da partição agrupada contra vazamento, do ajuste de hiperparâmetros, da comparação por validação cruzada com teste estatístico e da interpretação por permutação. Do ponto de vista prático, o erro percentual médio de 16,2%, no contexto de preços médios superiores a INR 480 mil, e o baixo custo de inferência do XGBoost viabilizam a aplicação do modelo em cenários de precificação assistida.

VI. CONCLUSÃO E TRABALHOS FUTUROS

Foi desenvolvido um fluxo completo e robusto de previsão de preços de carros usados, da limpeza de 8.128 registros à comparação de seis algoritmos por validação cruzada agrupada. O XGBoost obteve o melhor desempenho, com coeficiente de determinação de 0,916 no conjunto de teste, superando de forma estatisticamente significativa o gradient boosting, e tendo o ano, a potência e o torque como preditores dominantes. Em resposta às perguntas de pesquisa, confirmou-se a relevância dos atributos de idade e mecânica (PP1), a superioridade dos comitês sobre o *baseline* (PP2) e a vantagem do XGBoost em acurácia e estabilidade (PP3).

Como trabalhos futuros, propõem-se: a adoção de valores SHAP [12] para interpretação local; a inclusão de algoritmos adicionais, como *LightGBM* e redes neurais tabulares; o emprego de validação temporal; e a quantificação da incerteza das previsões por meio de intervalos de confiança.

REFERENCES

- [1] CarDekho/Kaggle, “Vehicle dataset — Car details v3,” conjunto de dados público de anúncios de carros usados, 2020. [Online].
- [2] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. New York: Springer, 2009.
- [3] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [4] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [5] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD*, 2016, pp. 785–794.
- [6] “Machine learning optimization and challenges in used car price prediction,” *ITM Web of Conferences*, 2025.
- [7] “Pre-owned car price prediction by employing machine learning techniques,” 2023.

- [8] “Revolutionizing the used car market: Predicting prices with XGBoost,” 2024.
- [9] N. Pal *et al.*, “How much is my car worth? A methodology for predicting used cars’ prices using random forest,” in *Proc. Future of Information and Communication Conf.*, 2018.
- [10] “Machine learning-powered mobile app for predicting used car prices,” in *Proc. ACM Conf.*, 2022.
- [11] “Used cars price prediction and valuation using data mining techniques,” M.S. thesis, Rochester Institute of Technology, 2022.
- [12] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017.
- [13] G. Bernardes Vitor, “PCO213 — Aprendizado de Máquina e Mineração de Dados,” Universidade Federal de Itajubá, 2026.